곽동우 Dongwoo Kwak

서울 · dong0881414@gmail.com · github.com/go-deung-eo · 포트폴리오

경력

디노티시아 (Dnotitia) 서울 강남구
AI Group 알고리즘팀 *Inference Optimization* 파트 · *Optimization Engineer* *2026.02* – 현재 (*9*개월)

- NPU 칩 Bring-up TF 온디바이스 LLM 에이전트 PoC(3인)에서 에이전트–추론 엔진 연동 담당. Session Activation Aware Warm-up 설계·구현, 5.7K 토큰 에이전트 프롬프트 첫 턴 TTFT 96% 단축(24.4초 → 0.9초).
- 팀 연구 2-bit n-gram 테이블 양자화를 MoE LLM 3종 vLLM에 포팅(Triton 융합 커널) — H200 4장에서 KV 캐시 54% 증가(TPOT 차이 0.6% 이내), FP8로 기동 불가하던 DeepSeek-V4.1-Flash 서빙 가능.
- 툴 사용 에이전트 스택 전체 대상 한/영 행동평가 하네스 개발, 8개 모델 pass@1 순위화 — 다국어 깨짐 토큰 원인을 vLLM 기본 temperature 1.0으로 규명(토크나이저·GPU·파서 요인 실험으로 배제).
- 사내 2B 임베딩 모델 서빙 엔진 3종 벤치마크 설계(코사인 0.999 관문) — 66,810 tokens/s, 358 img/s(SGLang 대비 3.1배) 실측, HTTP 200 뒤에 숨은 API 오류로 MTEB 0.848 → 0.718 열화 규명.
- MoE(512 expert) MTP 가속 역전(1.54배 → 16세션 0.83배) 원인을 nsys로 expert 경로 비례 FFN 비용으로 규명 — 라우팅 5.5만 토큰 시뮬레이션으로 expert 티어 파이프라인 중단 판정(이득 4–8%).
- 27B dense의 KV·attention 사내 가속기 오프로드 효과를 실물 없이 지연 주입 측정(세션 1–64)과 256K·1M 예상으로 정량화 — 카드당 상주 장문 대화 3.5배, 대화당 속도에 필요한 가속기 대역·연산 역산.

클레온 (Klleon) 서울 강남구
*Product AI*팀 · *AI Engineer* *2025.03 – 2026.01* (*10*개월)

- 8개월간 미해결이던 GPU 메모리 누수 원인을 Triton 클라이언트 소멸 시 공유 메모리 해제 누락으로 규명·수정 — OOM 크래시 0건, 3일 주기 강제 재시작 운영 폐지.
- GPT-SoVITS TTS 서버(CUDA Graph)에 동적 문장 배칭 도입 — 요청 수 75% 감소, E2E 지연 최대 80% 단축.
- 미디어 엔진 프로세스와 Triton 추론 노드 분리 설계 — 엔진:GPU 노드 10:1 → 50:3, AWS GPU 노드 40% 절감.
- 경량 얼굴 모델 깨진 프레임 0.85ms/frame 내 탐지(마스킹 히스토그램, OpenCV, CUDA) — 파드당 프로세스 2배.

티맥스클라우드 (Tmax Cloud) 경기 성남시
미들웨어 연구본부 · 연구원 *2024.02 – 2024.10* (*8*개월)

- Triton 기반 모델 서빙 IaaS(v0.0.0–v0.2.0) C++20 개발 — Triton core C API 포팅으로 추론·헬스체크·통계 비동기 호출 구현, Tensor Binary Encoding 확장 기능 추가.
- 통신 프레임워크 JSON 라이브러리 교체(boost::property_tree → glaze) — 직렬화 7배·역직렬화 3배 향상.
- GitLab CI/CD 4단계 파이프라인(빌드·이미지·E2E 테스트·배포) 구축, Python E2E 테스트 클라이언트 개발.

프로젝트

vLLM 서빙 툴킷 | *Bash, Python, FastAPI, vLLM* 2026

- 계층형 플래그 vLLM 런처·로깅 프록시·스모크 하네스 개발(TTFT·TPOT·툴콜 성공률 측정) — RTX 6000 Ada와 GB10에서 7개 모델 비교, 이후 벤치마크 4건에 재사용.

vLLM NGQ2 포팅 공개 fork | *Python, Triton, vLLM 0.31* 2026

- go-deung-eo/vllm (ngq2-ple): 3개 모델 2-bit 테이블 로더·TP 샤딩·pinned 호스트 배치 패치 (12파일 +822/−16), 320M행 테이블 CUDA Graph bit-exact, LongCat MLA layernorm 스케일 누락(PPL 706) 발견.

기술

언어: C++17/20, Python, CUDA(실무 활용), TypeScript
추론·서빙: vLLM, SGLang, NVIDIA Triton Inference Server, PyTorch/LibTorch, OpenCV, NPP, Prefix/KV 캐시
시스템: Linux(epoll, socket), Docker, Kubernetes, GitLab CI/CD, CMake, Meson, Conan, Grafana

학력

연세대학교 서울 서대문구
경제학 학사, 컴퓨터과학 부전공 · *GPA 3.56/4.5* *2018.03 – 2024.02*

- 운영체제(130명 중 10위), 데이터베이스, 컴퓨터구조, 데이터마이닝, 통계방법론. 42서울(2021–2023).

병역 · 자격 · 활동

병역: 공군 병장 만기전역(2012.05 – 2014.05), 공군참모총장실 비서실 행정병
자격·어학: OPIc IH(2026.09), SQLD, 한자능력검정 2급
활동: 연세대학교 조정부 주장(2018.08 – 2019.08), 전국대학조정대회 8+ 4위(2019)